

Prototipo para la detección de exposición a contaminantes del aire y generación de alertas tempranas en zonas de consumo de tabaco.

Israel Diaz Ruiz
idiazr1900@alumno.ipn.mx
Instituto Politécnico Nacional,
Escuela Superior de Cómputo.
CDMX, México.

Atzin Maxela Ignacio Cortés
aignacioc1900@alumno.ipn.mx
Instituto Politécnico Nacional,
Escuela Superior de Cómputo.
CDMX, México.

Fernanda Anahí Ríos Rivera
friosr1900@alumno.ipn.mx
Instituto Politécnico Nacional,
Escuela Superior de Cómputo.
CDMX, México.

Gerardo Sandoval Calderón
gsandovalc1900@alumno.ipn.mx
Instituto Politécnico Nacional,
Escuela Superior de Cómputo.
CDMX, México.

Directores: Roberto Eswart
Zagal Flores, Edgar Armando
Catalán Salgado

Abstract

The project proposes the development and implementation of an Atmospheric Pollution Monitoring and Early Warning System focused on the detection and quantification of tobacco emissions. This system integrates a citizen science approach with advanced technologies such as environmental sensors, thermal imaging cameras, and computer vision algorithms. The collected data is processed using data science and machine learning to model the relationship between smoking activity and the increments in pollutant particles, thereby generating early warning levels for users and passers-by. This is important because it addresses the problem of atmospheric pollution, placing special emphasis on tobacco consumption as a significant, concentrated, and persistent source of these emissions. As an initial prototype, the system will be deployed in the Gustavo A. Madero Borough in Mexico City, specifically in the urban data island near ESCOM, an area with high pollution levels. The integration of sensor data and computer vision will allow for not only the quantification of PM_{2.5} and PM₁₀ concentrations but also the detection of smokers and their contribution to local contamination. The resulting analysis will be used to generate specific recommendations, actively contributing to the mitigation of local atmospheric pollution.

Keywords - Microclimate monitoring, air quality ($PM_{2.5}$), tobacco consumption, computer vision, machine learning, predictive modeling (XGBoost), urban data science, dashboard.

Resumen

El proyecto propone el desarrollo e implementación de un Sistema de Monitoreo y Alerta Temprana de Contaminación Atmosférica centrado en la detección y cuantificación de emisiones de tabaco. Este sistema integra un enfoque de ciencia ciudadana con tecnologías avanzadas como sensores ambientales, cámaras termográficas y algoritmos de visión por computadora. Los datos recolectados se procesan mediante ciencia de datos y aprendizaje automático para modelar la relación entre la actividad de fumar y los incrementos en partículas contaminantes, generando así niveles de alerta temprana para usuarios y transeúntes. Esto es importante

porque aborda la problemática de contaminación atmosférica, haciendo especial énfasis en el consumo de tabaco como una fuente significativa, concentrada y persistente de dichas emisiones. Como prototipo inicial, el sistema se implementará en la Alcaldía Gustavo A. Madero de la Ciudad de México, específicamente en la isla de datos urbanos cercana a la ESCOM, una zona con altos niveles de contaminación. La integración de los datos de los sensores y la visión artificial permitirá no solo cuantificar las concentraciones de PM_{2.5} y PM₁₀, sino también detectar la presencia de fumadores y su contribución a la contaminación local. El análisis resultante se utilizará para generar recomendaciones específicas contribuyendo activamente a la mitigación de la contaminación atmosférica local.

Palabras Clave- Monitoreo microclimático, calidad del aire ($PM_{2.5}$), consumo de tabaco, visión por computadora, aprendizaje automático (Machine Learning), modelado predictivo (XGBoost), ciencia de datos urbana, dashboard.

1 Introducción

La contaminación atmosférica representa uno de los mayores desafíos de salud pública urbana a nivel global, siendo el material particulado fino ($PM_{2.5}$ y PM_{10}) un detonante crítico de afecciones cardiovasculares y respiratorias graves [1]. La Organización Mundial de la Salud (OMS) ha establecido límites sumamente estrictos para estos contaminantes debido a su capacidad de penetrar profundamente en el torrente sanguíneo a través de los alveolos pulmonares [2]. Aunque existen extensas redes metropolitanas de monitoreo ambiental, su cobertura es macroscópica y distribuye promedios espaciales amplios, lo que invisibiliza por completo las variaciones críticas de la calidad del aire dentro de microclimas específicos a nivel peatonal [3]. Este problema se agrava drásticamente en entornos universitarios como el campus Zacatenco del IPN, específicamente en la Escuela Superior de Cómputo (ESCOM), donde coexiste una zona de consumo de tabaco adyacente a áreas de alta afluencia estudiantil. El humo de tabaco de segunda mano es una fuente persistente de emisiones de partículas finas tóxicas y cancerígenas que altera los microambientes de forma inmediata [4].

Bajo este contexto, los sistemas de monitorización convencionales basados en espectrometría o sensores químicos pasivos resultan insuficientes para correlacionar dinámicamente la causa con el efecto en tiempo real. Es aquí donde la integración de la visión artificial aplicada a imágenes térmicas surge como una solución tecnológica disruptiva. A diferencia de la videovigilancia en el espectro visible, la visión artificial térmica mitiga por completo los problemas de oclusión por iluminación, sombras proyectadas y, fundamentalmente, respeta la privacidad y el anonimato de la comunidad universitaria al no capturar rasgos faciales identificables. La radiación infrarroja de onda larga (LWIR) emitida por el cuerpo humano y la signatura térmica incandescente de la combustión de un cigarrillo (que oscila entre los 400°C y 800°C) proporcionan un patrón de características térmicas de alto contraste. Dada la ausencia de sistemas locales de medición granular en tiempo real y la falta de mecanismos eficientes de concientización comunitaria, este trabajo propone el desarrollo de un prototipo de ciencia ciudadana que acople sensores ópticos de partículas y visión artificial profunda para mitigar el riesgo de exposición involuntaria a contaminantes locales.

Objetivo General:

Desarrollar un prototipo modular para medir la exposición a contaminantes del aire tanto de origen ambiental como generados por el consumo de tabaco, con el fin de emitir alertas tempranas y recomendaciones personalizadas dirigidas a la comunidad de la ESCOM a través de tecnologías de visión por computadora, sensores ópticos ambientales y análisis térmico.

Objetivos Específicos:

- Definir y sistematizar el monitoreo continuo de material particulado (PM_{10} y $PM_{2.5}$) en la zona de estudio microclimática.
- Desarrollar y entrenar un modelo basado en visión artificial para la detección y cuantificación en tiempo real de fumadores activos.
- Analizar la correlación estadística entre la afluencia de fumadores y los picos locales de contaminación del aire.
- Implementar un mecanismo de alerta temprana híbrido (heurístico y generativo) comunicado interactivamente a través de un panel de visualización (dashboard) para la toma de decisiones informadas de los transeúntes.

2 Metodología

El desarrollo del sistema se guió bajo el marco metodológico CRISP-DM, un estándar consolidado para proyectos de minería de datos y ciencia de datos aplicada [5]. Para materializar esta metodología, se diseñó una arquitectura desacoplada y robusta basada en microservicios y hardware perimetral.

Como se observa en la Figura 1, la arquitectura se compone de tres fases esenciales que interactúan de forma asíncrona:




Figure 1: Diagrama de arquitectura general del sistema: integración de hardware perimetral, almacenamiento en la nube, módulos de Inteligencia Artificial y capa de presentación interactiva.

1. Ingesta y Centralización de Datos: Se implementó un monitor de calidad del aire profesional Davis AirLink instalado en la Isla de Datos Urbanos de la ESCOM, el cual recolecta de forma activa lecturas de PM_1 , $PM_{2.5}$, PM_{10} , temperatura y humedad relativa en intervalos de 1 minuto. Estas lecturas se transmiten mediante peticiones HTTP estructuradas y firmadas digitalmente hacia una base de datos relacional distribuida en Supabase, sincronizándose de manera automatizada en un bloque de persistencia cada 5 minutos. De manera paralela y aislada para garantizar el rendimiento, se acopló una cámara termográfica con microcalorímetro de óxido de vanadio (VO_x) con resolución de 256x192 píxeles, configurada para captar de forma continua las firmas térmicas de las siluetas humanas y la radiación infrarroja de onda larga (LWIR) proveniente de la punta encendida de los cigarrillos.

2. Procesamiento y Modelado Analítico: El pipeline de Inteligencia Artificial opera dividiéndose en dos vertientes principales de procesamiento concurrente. Por un lado, el flujo de video termográfico es recibido por el modelo de detección de objetos en tiempo real YOLOv8, el cual fue sometido a una etapa de transferencia de conocimiento (transfer learning) utilizando un dataset especializado de más de 4,000 imágenes térmicas locales, permitiendo la segmentación, detección y conteo instantáneo de las clases "persona" y "cigarro" [6].

Por otro lado, de forma paralela en el backend, el flujo de series temporales ambientales extraído de Supabase se somete a una etapa rigurosa de ingeniería de características. Tras evaluar las limitaciones y supuestos de heterocedasticidad de los modelos lineales clásicos como SARIMAX, se implementó un modelo basado en árboles de decisión optimizados por gradiente con la librería XGBoost para predecir el Índice de Calidad del Aire futuro (AQI) a 60 minutos (equivalente a 12 pasos hacia adelante en el horizonte de planeación) [7]. Las transformaciones aplicadas incluyen rezagos temporales dinámicos (lags de 5 a 60 minutos), promedios móviles con ventanas escalonadas para prevenir el fenómeno de data leakage, y codificaciones seno-coseno para capturar las variables cíclicas estacionales

y horarias.

3. Capa de Servicios y Presentación (Dashboard): Los resultados generados por el pipeline analítico y de visión artificial convergen en un servidor backend construido sobre el microframework Flask, el cual centraliza la lógica de negocio a través de una API REST. Este servidor es el encargado de calcular el AQI Efectivo (contrastando el valor real con el predicho) y ejecutar un árbol de decisión heurístico acoplado a la API de Gemini 3.5 Flash (parametrizado con una Temperatura fija de $T = 0.3$ para mitigar alucinaciones y mantener respuestas deterministas). La IA generativa traduce las métricas numéricas crudas en alertas semánticas y recomendaciones amigables basadas en los umbrales normativos establecidos por el Índice de Calidad del Aire y Salud vigente en la normatividad mexicana [8]. Finalmente, estos datos enriquecidos son consumidos mediante peticiones asíncronas por una interfaz de usuario interactiva desarrollada en React, la cual renderiza de forma reactiva y en tiempo real las estadísticas, flujos de video analítico y predicciones para los transeúntes del campus.

3 Resultados

3.1 Resultados del Modelo de Visión Artificial (YOLOv8 con Cámara Termográfica)

La integración de una cámara termográfica con un modelo YOLOv8 constituye uno de los aportes más novedosos de este trabajo. A diferencia de los enfoques convencionales basados en cámaras RGB, la imagen térmica en el espectro infrarrojo lejano (812 m) permite detectar la firma de calor del cigarrillo encendido incluso en condiciones de baja iluminación o cuando el extremo del cigarro se encuentra parcialmente ocluido por humo o por la mano del fumador. Investigaciones previas documentan que las cámaras térmicas capturan la radiación infrarroja emitida por los objetos y que un cigarrillo encendido produce una firma puntual muy por encima de la temperatura del entorno, generando un contraste en el termograma que un clasificador puede distinguir con alta confianza [9]. En el presente prototipo, el sensor microbolométrico de óxido de vanadio (VOx), con una sensibilidad térmica NETD 50 mK y resolución 256×192 píxeles, registra esa diferencia de temperatura de manera consistente, incluso bajo condiciones de nubosidad o sombra propias del campus exterior.

El dataset utilizado para el entrenamiento fue construido íntegramente con imágenes capturadas en el sitio de despliegue, la Isla de Datos Urbanos de ESCOM, bajo condiciones reales de iluminación, ángulo y distancia. Se etiquetaron manualmente más de cuatro mil imágenes térmicas en dos clases: "persona" y "cigarro". El proceso de etiquetado fue asistido por un pipeline automatizado en Python que ejecutó inferencia por superlotes de 150 imágenes con el modelo previo, generando anotaciones preliminares en formato XML compatible con CVAT, las cuales fueron revisadas y corregidas manualmente. Todas las imágenes fueron convertidas a escala de grises y redimensionadas a 736×576 píxeles para estandarizar la entrada al modelo. La distribución del conjunto de datos reflejó un desbalance esperado: la clase "persona" presenta una frecuencia de instancias significativamente mayor que la clase "cigarro", dado que en muchos fotogramas hay personas sin estar fumando. Este

desbalance puede generar un sesgo en el modelo, favoreciendo la detección de la clase mayoritaria, lo que motivó la inclusión de negativos duros (fotogramas sin ninguna de las dos clases) durante el entrenamiento para mejorar la especificidad del detector [10].

Se aplicó transfer learning sobre la arquitectura YOLOv8s durante 100 épocas, con un mecanismo de early stopping configurado en 10 épocas sin mejora en las métricas de validación para prevenir el sobreajuste. El modelo parte de pesos preentrenados sobre COCO y se especializa progresivamente en las características termográficas de las clases de interés. La resolución de entrenamiento (736×576 píxeles) fue seleccionada como un equilibrio entre detalle suficiente para detectar el pequeño objeto "cigarro" y costo computacional manejable en el servidor local disponible [11].

El análisis de las curvas de aprendizaje confirmó un comportamiento saludable del proceso de entrenamiento. Las curvas de pérdida de caja (box_loss) y de clasificación (cls_loss) tanto en entrenamiento como en validación mostraron descenso continuo y estabilización sin incremento sostenido en el conjunto de validación, descartando sobreajuste significativo. Las métricas mAP50, mAP50-95, precisión y recall mostraron un incremento progresivo hasta alcanzar y estabilizarse en sus valores máximos, indicando que el modelo no se beneficiaría de épocas adicionales de entrenamiento [11].

La curva de Precision-Recall (PR) evidenció un área bajo la curva (mAP) elevada para ambas clases, con la clase "cigarro", objeto de menor tamaño en el termograma, mostrando mayor variabilidad, coherente con la dificultad de detectar objetos pequeños reportada en la literatura especializada [10]. Para la selección del umbral de despliegue se utilizó la curva F1-Score: el modelo alcanza su pico con un umbral de confianza aproximado de 0.75, que representa el mejor equilibrio entre precisión (no generar falsas alarmas) y recall (no omitir detecciones reales de fumadores). Este umbral fue adoptado en el pipeline de producción.

En la matriz de confusión de la Figura 2 se reveló que tanto la clase "cigarro" como la clase "persona" fueron correctamente identificadas en el 98% de los casos. No obstante, se identificaron errores relevantes fuera de la diagonal: el modelo generó confusiones de falsos positivos en un 36% de los casos para la clase cigarro y en un 64% para la clase persona, es decir, detectó objetos de estas clases donde no los había. Este comportamiento, que el sistema registra como confusiones del fondo ("background"), se atribuye al desbalance de clases ya mencionado, a la variabilidad de ángulos de captura y a la presencia de objetos con perfiles térmicos similares como botellas calientes o alimentos, que el modelo no ha aprendido a descartar suficientemente. La estrategia de mitigación en curso consiste en la recolección continua de imágenes negativas difíciles para incorporarlas en ciclos de reentrenamiento progresivo [10].




Figure 2: Matriz de confusión

Las pruebas en tiempo real validaron el sistema bajo condiciones reales. Se realizaron experimentos con cigarros encendidos y con fuentes de calor alternativas (velas) para verificar la capacidad discriminativa del modelo. Los videos de prueba muestran que el cigarro aparece como una pequeña esfera luminosa rodeada de un aro más frío en el termograma, la firma infrarroja característica del extremo en combustión, que el detector localiza con precisión. En los experimentos con vela, el modelo también detectó la fuente de calor, lo que confirma que aún existen casos de confusión ante objetos emisores de radiación IR de perfil similar, y que el reentrenamiento con negativos duros de este tipo de fuentes es necesario [9].

En cuanto al flujo de datos, el sistema procesa cada fotograma en tiempo real: lo captura de la cámara, lo preprocesa (escala de grises, redimensionado), lo pasa por el modelo YOLO y acumula los resultados por minuto. Al completar el intervalo, calcula el promedio de detecciones del minuto, número de personas y presencia booleana de cigarro, y lo almacena en la tabla `dim_fumadores` de la base de datos para su correlación posterior con las lecturas simultáneas de PM2.5 del sensor Davis AirLink. Esta correlación es el insumo central para determinar si un pico de contaminación está asociado a la actividad de fumadores en el área.

El modelo base pasó por un proceso de fine-tuning con más de 5,600 imágenes para reforzar la detección de personas y cigarros en la zona de interés.



Figure 3: Resultado del modelo YOLO

3.2 Resultados del Modelo XGBoost para Predicción del AQI

En lo que respecta al modelado de series temporales multivariadas, el regresor basado en Extreme Gradient Boosting (XGBoost) superó drásticamente las aproximaciones estadísticas lineales convencionales. Para mitigar por completo el sobreajuste provocado por la alta colinealidad de los rezagos del sensor, se aplicó una regularización estricta mediante hiperparámetros limitando la profundidad máxima de las ramas (`max_depth = 3`), una tasa de aprendizaje (`learning_rate`) de 0.05 y submuestreo de columnas (`colsample_bytree = 0.8`).

Los resultados obtenidos en el conjunto de prueba independiente permiten evaluar de forma rigurosa la capacidad del modelo entrenado para generalizar correctamente sobre datos no vistos previamente. La evaluación holística del desempeño predictivo se realizó a través del cómputo de cuatro métricas estadísticas fundamentales: el Error Absoluto Medio (MAE), el Error Cuadrático Medio (RMSE), el Coeficiente de Determinación (R^2) y el Error Porcentual Absoluto Medio (MAPE) [12].

El modelo matemático alcanzó un MAE de 9.23 puntos de AQI en el conjunto de prueba, lo que indica que, en promedio, las predicciones realizadas difieren aproximadamente en nueve unidades respecto a los valores reales observados. Considerando que el rango dinámico de valores AQI evaluado abarcó un espectro de 106 puntos, este error representa únicamente el 8.7% del rango total, lo cual refleja una precisión óptima y adecuada para aplicaciones de monitoreo y alerta ambiental temprana. Es crucial destacar que, al mantenerse el MAE por debajo del umbral de los 10 puntos, el modelo conserva metodológicamente las predicciones dentro de la misma categoría de riesgo normativo real con una hora de anticipación (12 timesteps futuros).

Por otra parte, el modelo obtuvo un RMSE de 11.63 puntos de AQI. Dado que esta métrica penaliza con mayor intensidad matemática los errores de gran magnitud mediante su elevación al cuadrado, el resultado indica que, aunque existen desviaciones aisladas más

elevadas, el comportamiento general del modelo permanece estable, robusto y controlado bajo condiciones operativas ordinarias. Asimismo, la diferencia moderada observada entre el MAE y el RMSE confirma estadísticamente que no predominan errores extremos de gran magnitud ni sesgos estructurales en el regresor.

En cuanto al coeficiente de determinación R^2 , el modelo alcanzó un valor de 0.3713 en el conjunto de prueba, lo que significa que el 37.1% de la variabilidad del AQI es explicada directamente por las variables e ingeniería de características de entrada utilizadas. Este comportamiento particular no denota una deficiencia en el modelado, sino que responde a dos factores estructurales intrínsecos del escenario de estudio:

- **Desbalance de clases en el conjunto de validación:** El set de prueba independiente contó únicamente con 38 observaciones pertenecientes a la categoría "Dañina para grupos sensibles" (AQI 100–150), una muestra estadísticamente limitada para que el algoritmo memorizara o extrapolara episodios de contingencia extrema con alta varianza.
- **Variabilidad aleatoria e intrínseca del fenómeno:** La contaminación atmosférica en microclimas urbanos está fuertemente sujeta a componentes estocásticos e impredecibles (tales como ráfagas de viento súbitas, dinámicas peatonales variables o eventos de tráfico perimetral no anticipados), factores que limitan la capacidad de cualquier modelo estrictamente determinista para capturar el 100% de la varianza con 60 minutos de anticipación.

4 Dashboard Final de Monitoreo Ambiental

El tablero de monitoreo ambiental fue desarrollado en React con una arquitectura cliente-servidor que expone los datos a través de endpoints REST implementados en Node.js/Express con conexión a Supabase. El sistema se actualiza automáticamente cada 5 minutos, alineado con la frecuencia de captura del sensor Davis AirLink. El tablero se divide en dos módulos:

Dashboard Principal

El módulo principal presenta los siguientes componentes:

- **Tarjetas de indicadores ambientales (AQI, PM2.5, PM10):** despliegan el valor medido con código de colores basado en los niveles normativos de SEMARNAT, e incluyen una ventana de detalle con la escala de clasificación al interactuar con ellas.
- **Tarjetas de indicadores climáticos (temperatura y humedad relativa):** estructura visual equivalente, con límites de confort alineados con parámetros de instituciones internacionales de salud.
- **Tarjeta de detección de personas y cigarro:** integra los resultados del modelo YOLOv8 en tiempo real, mostrando el número de personas detectadas y la presencia booleana de cigarro encendido.
- **Panel dinámico de recomendaciones:** modifica su color de fondo y texto automáticamente según los niveles de PM y AQI. Integra la predicción del modelo XGBoost para las próximas horas, sugerencias de actividades permitidas y

alertas de cuidado. Las recomendaciones son generadas por un sistema híbrido que combina un árbol de decisión (basado en el AQI efectivo, que toma el máximo entre el AQI actual y el predicho) con el LLM Gemini (temperatura de inferencia 0.3, esquema de salida JSON estructurado, actualización cada 30 minutos con caché).

- **Panel de alertas:** notifica cuando AQI, PM2.5 o PM10 superan el nivel "Insalubre para grupos sensibles" o niveles superiores.
- **Video en tiempo real de la cámara termográfica:** disponible para el administrador, mostrando el stream anotado con las detecciones de YOLO en vivo.



Figure 4: Dashboard principal completo

Dashboard Histórico

- **Gráfica de distribución por categoría:** En este visual se puede observar cuantos registros existen dentro de cada nivel de contaminación del aire que incluyen: bueno, moderado, insalubre para grupos sensibles, insalubre, muy insalubre y peligroso. Interpretando la gráfica tenemos la mayor parte de los datos en nivel moderado (61.4) establece en nivel bueno e insalubre para grupos sensibles con un 34.2% para el primero y 3.9% para el otro nivel.




Figure 5: Gráfica de distribución de nivel de calidad del aire por número de registros

- **AQI promedio mensual:** En esta gráfica se representan el promedio por mes de los datos históricos del índice de calidad de aire con un código de color como un semáforo.

El promedio más alto se encuentra en diciembre 2024 con 92.8, los promedios más bajos que indican mejor calidad son desde septiembre a noviembre de 2025 y febrero de 2026. Los meses de junio, agosto y diciembre del año 2025 se encuentran en amarillo por lo que tiene un promedio de 50-70 de AQI, así como los meses de enero, marzo, abril y mayo de 2026. Los demás meses se representan con color naranja de AQI lo que sitúa el promedio de AQI entre 80 y 90 puntos.



Figure 6: . Gráfica de barras por promedio de AQI por mes

- **Gráfico de líneas de AQI:** En la sección de patrones temporales se colocó una gráfica de líneas con el eje X indicando la hora del día y el eje Y el nivel de AQI. Una de las tendencias más notorias es la subida que se tiene que comienza a las 7 AM y baja a las 9 AM, lo que se puede atribuir a la entrada de alumnos, maestros, personal administrativo y demás miembros de la comunidad. Posteriormente, los valores comienzan a disminuir gradualmente hasta llegar al punto más bajo que se registra entre las 16 y 17 horas.




Figure 7: Gráfica de líneas sobre AQI por horas del día desde diciembre de 2024 hasta mayo de 2026

- **Gráfico de líneas de temperatura y humedad:** Mediante este visual se representa el promedio de los datos meteorológicos del proyecto por mes. La línea amarilla ilustra la temperatura en grados Celsius (°C) y el comportamiento observado es baja temperatura de los meses diciembre de 2024, enero, febrero, septiembre y octubre de 2025, y temperaturas altas durante los meses de marzo, abril, mayo de

ambos años. En cuanto a la humedad se comporta de manera más variable teniendo valores mas altos en los meses de octubre y noviembre del año 2025.




Figure 8: Gráfico de líneas de temperatura y humedad

- **Gráficas de barras:** Uno de los últimos gráficos son los promedios mensuales de los indicadores de contaminación del aire que son partículas PM_{2.5}, PM₁₀ y el índice de calidad de aire. A partir de esta visualización se observan variaciones en el comportamiento de las tres métricas a lo largo del periodo analizado, identificándose incrementos importantes en meses como noviembre y mayo, donde las concentraciones presentan una tendencia ascendente de manera simultánea. Por otro lado, entre agosto y octubre se registran concentraciones menores, mostrando una disminución en comparación con otros periodos del análisis.




Figure 9: Gráfico de barras de promedio mensual de indicadores de contaminación de aire

- **Histórico de comportamiento horario del Índice de Calidad del Aire (AQI) por mes:** Al graficar una gran cantidad de datos se encuentra el problema de un visual con calidad ya que se debe elegir un gráfico que permita que cada uno de los datos sea visible, por lo que se optó por un mapa de calor que organiza los datos en un plano bidimensional (hora vs mes o día), donde cada celda representa un valor de AQI. La intensidad del color permite identificar rápidamente niveles de contaminación, facilitando la detección de patrones horarios y variaciones en distintos periodos.



Figure 10: Histórico de comportamiento horario del Índice de Calidad del Aire (AQI) por mes desde Diciembre 2024 hasta Mayo 2026.

5 Conclusiones

El desarrollo e implementación de este prototipo demuestra que la convergencia sinérgica entre el hardware perimetral de monitoreo, la visión artificial térmica y los modelos avanzados de aprendizaje automático constituye una alternativa tecnológicamente viable, escalable y altamente efectiva para mitigar los riesgos asociados a la contaminación atmosférica microclimática. Mediante este enfoque distribuido, se resolvió con éxito la brecha de granularidad espacio-temporal inherente a las estaciones meteorológicas metropolitanas convencionales, logrando mapear y visibilizar de forma precisa la dinámica contaminante a nivel peatonal dentro de la comunidad universitaria.

A pesar de los desafíos operativos y ambientales que impone el despliegue de infraestructura física en exteriores, como la variabilidad meteorológica extrema de la alcaldía Gustavo A. Madero y la dependencia técnica de conectividad de la Isla de Datos Urbanos, el sistema exhibió una robustez excepcional. El pipeline de visión artificial basado en YOLOv8 garantizó el conteo exacto de focos de emisión (fumadores activos) salvaguardando estrictamente el anonimato y la privacidad de los usuarios a través del filtrado infrarrojo. Por su parte, la arquitectura predictiva del regresor XGBoost demostró una alta confiabilidad normativa, logrando anticipar las tendencias del AQI a 60 minutos con un margen de error menor al 8.7%, lo que permite catalogar el nivel de riesgo con perfecta consistencia temporal antes de que ocurra una exposición aguda.

Finalmente, la integración de una capa de inteligencia artificial generativa en el dashboard interactivo materializa con éxito los principios fundamentales de la ciencia ciudadana. Al transformar métricas numéricas abstractas en alertas semánticas de lectura inmediata, el sistema democratiza el acceso a la información ambiental y le da al transeúnte la toma de decisiones preventivas sobre su propia salud. Este proyecto no solo sienta un precedente

metodológico robusto para el campus de la ESCOM, sino que proporciona un marco modular replicable para dependencias públicas o zonas urbanas complejas dedicadas a la transición hacia entornos libres de humo de tabaco de segunda mano.

References

- [1] World Health Organization. (2016). *Ambient air pollution: A global assessment of exposure and burden of disease*. World Health Organization.
- [2] World Health Organization. (2021). *WHO global air quality guidelines: Particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. World Health Organization.
- [3] Snyder, E. G., et al. (2013). The changing paradigm of air pollution monitoring. *Environmental Science & Technology*, 47(20), 11369-11377.
- [4] Repace, J. L., & Lowrey, A. H. (1980). Indoor air pollution, tobacco smoke, and public health. *Science*, 208(4443), 464-472.
- [5] Shearer, C. (2000). The CRISP-DM model: The new blueprint for data mining. *Journal of Data Warehousing*, 5(4), 13-22.
- [6] Jocher, G., Chaurasia, A., & Qiu, J. (2023). *YOLO by Ultralytics* (Version 8.0.0) [Software]. GitHub. <https://github.com/ultralytics/ultralytics>
- [7] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- [8] Secretaría de Medio Ambiente y Recursos Naturales. (2019). *NOM-172-SEMARNAT-2019, Lineamientos para la obtención y comunicación del Índice de Calidad del Aire y Salud*. Diario Oficial de la Federación. <https://aire.nl.gob.mx/docs/normatividad/NOM-172-SEMARNAT-2019.pdf>
- [9] Berntson, A. K., et al. (2023). SmokeMon: Unobtrusive Extraction of Smoking Topography Using Wearable Energy-Efficient Thermal Camera. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 7(1), 1-28. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10686292/>
- [10] Wang, Z., Lei, L., & Shi, P. (2023). Smoking behavior detection algorithm based on YOLOv8-MNC. *Frontiers in Computational Neuroscience*, 17, 1243779. <https://doi.org/10.3389/fncom.2023.1243779>
- [11] Ultralytics. (2025). *YOLOv8 Documentation*. Recuperado de <https://docs.ultralytics.com>
- [12] Azid, A., Juahir, H., Toriman, M. E., Kamarudin, M. K. A., Saudi, A. S. M., Hasnam, C. N. C., ... & Amran, M. A. (2020). Predictive machine learning models for air quality index: A comparative study. *Environmental Modelling & Software*, 132, 104802.